

Laboratorio II – Modelos de lenguaje a nivel de caracteres con RNN

Procesamiento de Lenguaje Natural – 2026 S02 – Universidad Sergio Arboleda

Estudiante: Julián Rincón

Entregables

Entregable	Enlace / ubicación
Sitio web funcionando	<code>https://zk6dst5eom6dhbjfcivxejcpn40iakbw.lambda-url.us-east-1.on.aws/</code>
Repositorio	<code>https://github.com/Julian-Rincon/dino-island-lab2</code>
README con instrucciones	<code>README.md</code> en la raíz del repositorio
Generador de nombres	<code>1_generador_nombres/entrenar.py</code>
Configuración de Ollama	<code>2_ollama_sagemaker/on-start.sh</code> , <code>identidad_ollama.ipynb</code> , <code>prompt_identidad.txt</code>
Código de generación de imágenes	<code>3_imagen/colab_imagen.ipynb</code> , <code>3_imagen/servidor_imagen.py</code>
Archivos de la aplicación	<code>4_app/lambda/</code> (página + orquestador) y <code>4_app/deploy.sh</code>
Evidencias experimentales	<code>1_generador_nombres/resultados/</code> (configuración, curvas, muestreo, 10 nombres)

El sitio depende del notebook de SageMaker `ollama`; debe estar encendido para usarlo.

Cómo se realizó

1. Nombre. Se normalizaron los 1536 nombres de `dinos.csv` (minúsculas, solo a-z), se construyó el vocabulario con `<PAD>`, `<BOS>` y `<EOS>` (29 tokens), se fijó $T = 27$, se rellenó con `<PAD>` y se formaron X e Y desplazadas un carácter. Se compararon dos modelos: **LSTM 1x128** y **GRU 2x256**, con Adam y entropía cruzada que ignora `<PAD>`. Las curvas muestran que ambos sobreajustan después de la época 11-14, así que se guardó la mejor época de validación. Ganó la GRU (pérdida de validación 1,564). Se compararon temperaturas 0,5, 1,0 y 1,5, top-k = 5 y top-p = 0,9. Top-p 0,9 dio el mejor equilibrio entre nombres nuevos y forma de nombre real. De los 10 nombres nuevos se eligió **Limedsaurus**.

2. Identidad. En un notebook de SageMaker `ml.m5.xlarge` se instaló Ollama con Docker y se descargó `gemma4:e2b` (digest `b37049369adf`, 4.6B, Q4_K_M). Un lifecycle script `on-start` deja el data-root de Docker, los modelos y la caché en `/home/ec2-user/SageMaker`, así que todo sobrevive a los reinicios. El prompt da ejemplos de raíces reales (`-saurus`, `-raptor`, `-odon`, `-venator...`) y pide en JSON la apariencia, el hábitat, la alimentación, el comportamiento y el rasgo distintivo. Resultado: Limedsaurus es un depredador del Jurásico Tardío, gris pizarra, con placas óseas y una cresta para intimidar.

3. Imagen. Con `amused/amused-512` (diffusers, transformers, torch, accelerate, safetensors) se generó la imagen a partir del nombre y los rasgos de Ollama. El notebook se ejecutó en GPU (1,6 s por imagen). La app usa el mismo código como servicio dentro del notebook de SageMaker (CPU, ~45 s). Así no depende de una sesión de Colab abierta.

4. Integración. Una función AWS Lambda con URL pública sirve la página y orquesta el flujo *nombre* → *identidad* → *imagen* → *chat*. Hace el muestreo con la GRU exportada a numpy, sin reentrenar. Llega a Ollama y al generador de imágenes por el proxy interno del notebook, con una URL prefirmada. Los dinosaurios y sus imágenes se guardan en un bucket S3 privado. Cada imagen se genera una sola vez y se reutiliza. El chat envía la identidad como contexto en cada mensaje y el dinosaurio no la contradice. Al presentarse o al describirse, el mensaje incluye la imagen. El botón **Nuevo dinosaurio** repite todo en unos 2 minutos. El README documenta qué recibe y qué devuelve cada componente.

Verificación (sección 9 de la guía)

Se automatizó en `pruebas/` (pytest y un navegador real con Playwright, contra el sitio desplegado). El resultado está en `pruebas/REPORTE.md`.

Punto de la guía	Resultado
Los 10 nombres no son copias del dataset	✓ comprobado contra <code>dinos.csv</code>
Identidad coherente	✓ carnívoro ↔ depredador, dientes, caza
La imagen corresponde a los rasgos	✓ gris, placas, pantano brumoso (revisión visual)
El chat conserva la identidad	✓ ante "¿eres herbívoro?" responde que es carnívoro
La imagen aparece al presentarse o describirse	✓ y no aparece en preguntas normales
Nuevo Dinosaurio sin reentrenar	✓ probado con el botón en el navegador
Sitio accesible	✓
Repositorio con instrucciones y sin información sensible	✓ búsqueda automática de claves y tokens